

Khung Toán Học Cho Phương Pháp Future RCA và Phân Tích Nhân Quả Vi Dịch Vụ (Bản Luận Giải Khoa Học Chặt Chẽ - Phiên Bản v3)

Đề Xuất Nghiên Cứu Học Thuật - Phiên Bản v3

August 31, 2026

Contents

1	Giới thiệu Khung Lý Thuyết Nhân Quả	2
1.1	Đồ thị có hướng phi chu trình (DAG) và Mô hình Nhân quả Hàm số (FCM) . . .	2
1.2	Vai trò của Giả định Độc lập Nhiều	2
2	Thước đo Ngoại lệ và Phép Tích chập Hệ thống	3
2.1	Thước đo Ngoại lệ Lý thuyết Thông tin (IT Outlier Score)	3
2.2	Định lý Tích chập Điểm số (Convolution Score)	4
3	Cô lập Lỗi bằng Điểm Ngoại lệ Có Điều Kiện	4
3.1	Cơ chế lọc nhân quả (Causal Filtering)	5
4	Quy trình Định vị và Phân bổ Lỗi 4 Bước	5
4.1	Bước 1: Khớp mô hình nhân quả nền (Fitting Phase)	5
4.2	Bước 2: Tái dựng biến nhiễu lỗi (Noise Reconstruction Phase)	6
4.3	Bước 3: Mô phỏng bối cảnh kịch bản điều kiện (Conditioning Phase)	6
4.4	Bước 4: Phân rã Shapley và quy đổi trách nhiệm (Aggregation Phase)	6
5	Chứng minh Toán học cho Đề xuất Dự phóng (Future RCA)	7
5.1	Phát biểu Phạm vi Hẹp của Nghiên cứu (Scope Definition)	7
5.2	Luận điểm 1: Định lý Phân rã Cắt cụt (Truncated Factorization Theorem) . . .	7
5.3	Luận điểm 2: Sự bảo toàn tính độc lập của các nguồn nhiễu	7
5.4	Luận điểm 3: Tính bất biến cấu trúc hàm mục tiêu và sự hội tụ của Theorem 3 .	8
5.5	Luận điểm 4: Rào cản an toàn hệ thống thông qua Bổ đề 3 (Lemma 3)	8
6	Cảnh báo Học thuật và Thách thức Thực tế (Limitations & Risks)	9
6.1	Rủi ro chồng ba tầng suy luận (Triple-Decker Inference Risk)	9
6.2	Cảnh báo ngoại suy ngoài miền phân phối (OOD Extrapolation Failure)	9
6.3	Độ nhạy đối với kích thước hệ thống (Scale Sensitivity)	9
6.4	Không có phương pháp nhân quả nào chiến thắng trong mọi tình huống	10

1 Giới thiệu Khung Lý Thuyết Nhân Quả

Nền tảng toán học kế thừa từ công trình nghiên cứu cốt lõi của Janzing, Budhathoki, Minorics và Blöbaum (2019), “*Causal structure based root cause analysis of outliers*”, công bố tại Hội nghị Quốc tế về Học máy (ICML 2019). Khung lý thuyết này thiết lập một phương pháp luận toán học chặt chẽ để phân tích sự cố dựa trên mô hình cấu trúc nhân quả, dịch chuyển hoàn toàn khỏi các phương pháp thống kê tương quan truyền thống.

1.1 Đồ thị có hướng phi chu trình (DAG) và Mô hình Nhân quả Hàm số (FCM)

Trong một hệ thống gồm n biến quan sát được $X_1, \dots, X_n$, cấu trúc nhân quả giữa chúng được biểu diễn bởi một Đồ thị có hướng phi chu trình (Directed Acyclic Graph - DAG), ký hiệu là G . Sự phân rã phân phối xác suất đồng thời $P(X_1, \dots, X_n)$ tuân thủ nghiêm ngặt **Điều kiện Markov Nhân quả** (Causal Markov Condition), cho phép biểu diễn hàm mật độ liên hợp dưới dạng tích các phân phối có điều kiện:

$$p(x_1, \dots, x_n) = \prod_{j=1}^n p(x_j \mid pa_j) \quad (1)$$

Trong đó pa_j đại diện cho các giá trị thực nghiệm thu được từ tập hợp các nút cha trực tiếp PA_j của nút X_j trên đồ thị G .

Để mô tả chi tiết hơn cơ chế sinh dữ liệu động tại mỗi nút, Janzing et al. (2019) sử dụng **Mô hình Nhân quả Hàm số** (Functional Causal Models - FCM).

Mô hình nhân quả cấu trúc dạng hàm số (FCM) được nhóm tác giả phát biểu nguyên bản trong nghiên cứu như sau:

*“Each variable is given by a function of its parents and an unobserved noise variable:
 $X_j = f_j(PA_j, N_j)$, where the noise variables $N_1, \dots, N_n$ are jointly statistically independent.” (Janzing et al., 2019, p. 2)*

Ý nghĩa học thuật và phân tích bản chất cơ chế vận hành hệ thống:

$$X_j = f_j(PA_j, N_j) \quad (2)$$

Trong đó:

- f_j là cơ chế nhân quả (hàm số xác định).
- N_j là biến nhiễu nội tại đại diện cho tính ngẫu nhiên cục bộ không quan sát được của riêng nút X_j .
- Các biến nhiễu $N_1, \dots, N_n$ độc lập thống kê đồng thời với nhau ($N_1 \perp\!\!\!\perp N_2 \perp\!\!\!\perp \dots \perp\!\!\!\perp N_n$).

1.2 Vai trò của Giả định Độc lập Nhiễu

Giả định độc lập đồng thời của các biến nhiễu ẩn đóng vai trò là xương sống toán học của toàn bộ thuật toán nhờ ba tính chất quyết định:

1. **Tính chất cô lập xung lực ngoại lệ (Outlier Decoupling):** Nó khẳng định rằng mọi biến động bất thường phát sinh cục bộ tại mỗi thực thể (nhiễu nội tại N_j) đều độc lập về mặt vật lý (ví dụ: lỗi code, Garbage Collection Pause, hoặc Memory Leak). Sự bất thường chỉ có thể lan truyền dọc theo đồ thị thông qua các cạnh có hướng của cấu trúc hàm $f_j(PA_j)$.

2. **Bảo chứng cho Định lý Tích chập (Theorem 1):** Sự độc lập của các biến nhiễu kéo theo sự độc lập của các điểm ngoại lệ thành phần, cho phép xây dựng phép tích chập điểm số chuẩn hóa.
3. **Hội tụ của Phép phân rã Shapley (Theorem 3):** Đảm bảo phép toán lấy mẫu Monte Carlo khi cố định một nhóm biến nhiễu lỗi n_T^* không làm thay đổi phân phối baseline của các biến nhiễu còn lại.

2 Thước đo Ngoại lệ và Phép Tích chập Hệ thống

2.1 Thước đo Ngoại lệ Lý thuyết Thông tin (IT Outlier Score)

Để lượng hóa mức độ bất thường của một quan sát mà không phụ thuộc vào thứ nguyên vật lý hay dạng phân phối xác suất cụ thể của biến số, Janzing et al. (2019) định nghĩa thước đo ngoại lệ dựa trên lượng tin Shannon:

Thước đo lượng tin ngoại lệ (IT Outlier Score) được định nghĩa chính thức trong bài báo dưới dạng tiếng Anh như sau:

“Let X be a random variable with values in $\mathcal{X}$ and distribution P_X . An information theoretic (IT) outlier score is a measurable function $S_X : \mathcal{X} \rightarrow \mathbb{R}_0^+$ such that:

$$P\{S_X(X) \geq c\} \leq e^{-c} \quad \forall c \in \mathbb{R}_0^+$$

and

$$P\{S_X(X) \geq S_X(x)\} = e^{-S_X(x)}$$

for P_X -almost all $x \in \mathcal{X}$.” (Janzing et al., 2019, p. 2)

Ý nghĩa khoa học và phân tích các thuộc tính toán học liên quan:

Định nghĩa 1 (Information Theoretic Scores). *Cho X là biến ngẫu nhiên nhận giá trị trong không gian $\mathcal{X}$ với phân phối xác suất P_X . Một điểm ngoại lệ lý thuyết thông tin (IT Outlier Score) là một hàm đo lường được $S_X : \mathcal{X} \rightarrow \mathbb{R}_0^+$ sao cho:*

$$P\{S_X(X) \geq c\} \leq e^{-c} \quad \forall c \in \mathbb{R}_0^+ \tag{3}$$

và

$$P\{S_X(X) \geq S_X(x)\} = e^{-S_X(x)} \tag{4}$$

cho P_X -hầu hết $x \in \mathcal{X}$.

Từ định nghĩa này, tác giả chứng minh hai bổ đề quan trọng bảo chứng cho tính chất toán học của thước đo:

Bổ đề 1 (Phân phối của điểm số). *Đối với bất kỳ điểm số IT Outlier Score chuẩn hóa S , phân phối của $S(X)$ trên miền dương $[0, \infty)$ có hàm mật độ xác suất chính xác là $p(s) = e^{-s}$.*

Bổ đề 2 (Biểu diễn dựa trên hàm số). *Mọi IT Outlier Score đều có thể biểu diễn dưới dạng log-quantile nghịch đảo thông qua một hàm đo lường $f(x)$ bất kỳ:*

$$S_f(x) := -\log P\{f(X) \geq f(x)\} \tag{5}$$

Bất kể biến nguyên bản X tuân theo phân phối phức tạp hay phi tuyến nào, việc áp dụng hàm log-quantile nghịch đảo sẽ đồng nhất hóa toàn bộ không gian xác suất về không gian phân phối mũ tiêu chuẩn (Standard Exponential Space).

2.2 Định lý Tích chập Điểm số (Convolution Score)

Khi đánh giá mức độ bất thường đồng thời của một hệ thống đa biến gồm nhiều thực thể độc lập, việc cộng trực tiếp các điểm số đơn lẻ sẽ tích lũy sai số và gây ra hiện tượng bão bão động. Janzing et al. (2019) giải quyết bài toán đa kiểm thử này bằng phép tích chập điểm số:

Để kiểm soát tỷ lệ báo động giả, Định lý 1 (Theorem 1) về phép tích chập điểm số được phát biểu nguyên bản như sau:

“Let P be a product distribution on $\mathcal{X} := \mathcal{X}_1 \times \cdots \times \mathcal{X}_n$. Let $S_1, \dots, S_n$ be surjective information theoretic outlier scores. Then:

$$(S_1 * \cdots * S_n)(x_1, \dots, x_n) = \sum_{j=1}^n S_j(x_j) - \log \sum_{i=0}^{n-1} \frac{\left(\sum_{j=1}^n S_j(x_j)\right)^i}{i!}$$

” (Janzing et al., 2019, p. 3)

Dịch nghĩa học thuật và phép chứng minh toán học chi tiết:

Định lý 1 (Multiple Convolution). *Let P be a product distribution on $\mathcal{X} := \mathcal{X}_1 \times \cdots \times \mathcal{X}_n$. Let $S_1, \dots, S_n$ be surjective information theoretic outlier scores. Then:*

$$(S_1 * \cdots * S_n)(x_1, \dots, x_n) = \sum_{j=1}^n S_j(x_j) - \log \sum_{i=0}^{n-1} \frac{\left(\sum_{j=1}^n S_j(x_j)\right)^i}{i!} \quad (6)$$

Proof. Vì các điểm số thành phần $S_j(x_j)$ độc lập thống kê và tuân theo phân phối mũ tiêu chuẩn e^{-s_j} , hàm mật độ xác suất liên hợp trên góc phần tư dương của không gian $\mathbb{R}^n$ là $p(s_1, \dots, s_n) = e^{-\sum_{j=1}^n s_j}$. Xác suất để tổng các điểm số vượt quá một ngưỡng s bất kỳ được tính bằng tích phân lớp trên miền đơn hình (simplex) $\sum_{j=1}^n s_j \geq s$:

$$P \left\{ \sum_{j=1}^n S_j(X_j) \geq s \right\} = \int_{\sum s_j \geq s} e^{-\sum_{j=1}^n s_j} ds_1 \dots ds_n \quad (7)$$

Thực hiện phép thế biến sang tọa độ đơn hình $\mathbb{R}^{n-1}$ có kích thước s' , tích phân chuyển dịch về dạng:

$$\int_s^\infty e^{-s'} \frac{(s')^{n-1}}{(n-1)!} ds' = e^{-s} \sum_{i=0}^{n-1} \frac{s^i}{i!} \quad (8)$$

Lấy trừ logarit tự nhiên ($-\log$) của xác suất đuôi này, ta thu được chính xác biểu thức toán học của định lý. $\square$

Lượng trừ logarit về phải đóng vai trò như một **bộ hiệu chỉnh cho việc kiểm thử đa giả thuyết** (correction term for multihypothesis testing). Nó triệt tiêu hiện tượng tăng điểm số ảo do quy mô biến số lớn, đảm bảo điểm tích chập của hệ thống vẫn là một IT score chuẩn mực.

3 Cô lập Lỗi bằng Điểm Ngoại lệ Có Điều Kiện

Để chẩn đoán xem một trạng thái bất thường tại một nút con Y là do chính nó tự sinh hay do lây lan từ thượng nguồn (cha trực tiếp X), tác giả thiết lập khái niệm điểm ngoại lệ có điều kiện dựa trên cơ chế nhân quả:

Định nghĩa 4 (Definition 4) về mô hình FCM cho điểm ngoại lệ có điều kiện được phát biểu nguyên bản dưới dạng:

“A conditional IT outlier score $S_{Y|X}$ is said to have an FCM if there is an FCM $Y = f(X, N)$ with range $\mathcal{N}$ for $P_{Y|X}$ and an IT score $S_N(N)$ such that N is a function of (X, Y) and:

$$S_{Y|X}(Y, X) = S_N(N)$$

if and only if $X \perp\!\!\!\perp S_{Y|X}(Y|X)$.” (Janzing et al., 2019, p. 4)

Ý nghĩa khoa học và phân tích các thuộc tính toán học liên quan:

Định nghĩa 2 (FCM for Conditional Score). Một điểm ngoại lệ có điều kiện $S_{Y|X}$ được gọi là có mô hình FCM nếu tồn tại một mô hình nhân quả cấu trúc $Y = f(X, N)$ cho phân phối điều kiện $P_{Y|X}$ và một điểm số ngoại lệ IT của biến nhiễu $S_N(N)$ sao cho N là một hàm số của (X, Y) và:

$$S_{Y|X}(Y, X) = S_N(N) \quad (9)$$

nếu và chỉ nếu $X \perp\!\!\!\perp S_{Y|X}(Y|X)$.

3.1 Cơ chế lọc nhân quả (Causal Filtering)

Sự tồn tại của mô hình nhân quả ANM ($Y = f(X) + N_Y$) đóng vai trò như một bộ lọc thông tin. Khi hệ thống tính toán điểm ngoại lệ có điều kiện $S(y | x)$, nó thực hiện phép tính ngược để cô lập biến nhiễu nội tại:

$$n_y^* = y - f(x) \quad (10)$$

Khi đó, xác suất điều kiện của biến quan sát được rút gọn trực tiếp về xác suất của biến nhiễu độc lập:

$$P\{Y \geq y | X = x\} = P\{f(x) + N_Y \geq y\} = P\{N_Y \geq y - f(x)\} = P\{N_Y \geq n_y^*\} \quad (11)$$

Lấy trừ logarit tự nhiên ($-\log$) hai vế, ta thu được đẳng thức:

$$S_{Y|X}(y, x) = S_{N_Y}(n_y^*) \quad (12)$$

- **Trường hợp 1 (Nút con vô tội):** Lỗi từ cha X truyền xuống khiến Y bị vọt lớn, nhưng hiệu số $n_y^* = y - f(x) \approx 0$. So với phân phối baseline, trị số này rất phổ biến, dẫn đến điểm ngoại lệ $S_{N_Y}(n_y^*) \approx 0$. Hệ thống kết luận nút con vô tội.
- **Trường hợp 2 (Nút con lỗi tự sinh):** Dù cha X hoạt động bình thường, nút con Y vẫn chậm vọt lên, khiến $n_y^* = y - f(x) \gg 0$. Trị số nhiễu này cực kỳ hiếm gặp, khiến điểm ngoại lệ $S_{N_Y}(n_y^*)$ bùng nổ rất cao. Hệ thống kết luận nút con chính là nguyên nhân gốc rễ.

4 Quy trình Định vị và Phân bổ Lỗi 4 Bước

Quy trình tìm lỗi (outlier attribution) của Janzing et al. (2019) được thực hiện qua 4 pha chặt chẽ:

4.1 Bước 1: Khớp mô hình nhân quả nền (Fitting Phase)

Huấn luyện đồ thị DAG, học các hàm dự báo f_j và phân phối của các biến nhiễu độc lập $P(N_j)$ từ dữ liệu lịch sử bình thường (baseline):

$$X_j = f_j(PA_j, N_j) \quad \text{với} \quad N_j \sim P(N_j) \quad (13)$$

4.2 Bước 2: Tái dựng biến nhiễu lỗi (Noise Reconstruction Phase)

Khi xảy ra sự cố tại một thời điểm cụ thể với vector lỗi thực tế quan sát được $x^* = (x_1^*, \dots, x_n^*)$, thực hiện phép tính ngược toán học để bóc tách trị số nhiễu lỗi thực tế:

$$n_j^* = x_j^* - f_j(pa_j^*) \quad (14)$$

4.3 Bước 3: Mô phỏng bối cảnh kịch bản điều kiện (Conditioning Phase)

Công thức xác định đóng góp biên của một nút vào liên minh được mô tả nguyên văn tại Section 5 của nghiên cứu:

“First, we define the contribution of j , given some set $T \subset \{1, \dots, n\} =: U$ not containing j , by:

$$c_x(j | T) := \log P\{S(X_n) \geq S(x_n) | n_{T \cup \{j\}}\} - \log P\{S(X_n) \geq S(x_n) | n_T\}$$

” (Janzing et al., 2019, p. 5)

Ý nghĩa học thuật và phân tích cơ chế tính toán thực tế: Để định lượng mức đóng góp của từng nút j khi tham gia vào liên minh T (các nút đã được cố định giá trị nhiễu lỗi n_T^*), ta tính giá trị đóng góp biên (marginal contribution) thông qua Equation (7):

$$c_x(j | T) := \log P\{S(X_n) \geq S(x_n) | n_{T \cup \{j\}}\} - \log P\{S(X_n) \geq S(x_n) | n_T\} \quad (15)$$

Xác suất đuôi có điều kiện $P\{S(X_n) \geq S(x_n) | n_T\}$ được ước lượng bằng **Mô phỏng Monte Carlo** trên đồ thị FCM: khóa cứng $N_k = n_k^*$ với $k \in T$, lấy mẫu ngẫu nhiên $N_m \sim P(N_m)$ với $m \notin T$, và chạy lan truyền xuôi dòng.

4.4 Bước 4: Phân rã Shapley và quy đổi trách nhiệm (Aggregation Phase)

Định lý 3 (Theorem 3) bảo chứng toán học cho tính chất phân rã hoàn hảo điểm lỗi được phát biểu nguyên bản:

“The outlier score of any variable decomposes into the contribution of each of its ancestors:

$$S(x_n) = \sum_{j=1}^n cSh_x(j)$$

” (Janzing et al., 2019, p. 5)

Bên cạnh đó, cơ chế và ý nghĩa của việc đóng góp biên nhận trị số âm được tác giả biện giải nguyên văn như sau:

“Note that this contribution can be negative which makes perfectly sense: one value being extreme can certainly weaken the outlier of the target, that is, a more common value at that node would have made the outlier even stronger.” (Janzing et al., 2019, p. 6)

Ý nghĩa khoa học và phân tích bản chất hệ thống: Áp dụng giá trị Shapley để lấy trung bình trọng số đóng góp biên trên mọi hoán vị tổ hợp liên minh:

$$cSh_x(j) := \sum_{T \subset U \setminus \{j\}} \frac{1}{n} \binom{n-1}{|T|}^{-1} c_x(j | T) \quad (16)$$

Định lý 2 (Decomposition of Target Outlier Score). *Điểm ngoại lệ của bất kỳ biến mục tiêu nào cũng được phân rã hoàn hảo thành tổng đóng góp của từng nút tổ tiên trực hệ của nó:*

$$S(x_n) = \sum_{j=1}^n cSh_x(j) \quad (17)$$

5 Chứng minh Toán học cho Đề xuất Dự phóng (Future RCA)

5.1 Phát biểu Phạm vi Hẹp của Nghiên cứu (Scope Definition)

Trước khi đi vào chi tiết toán học, chúng tôi phát biểu rõ ràng phạm vi ứng dụng thực tế của phương pháp này. Nghiên cứu tập trung duy nhất vào bài toán “**SCM-based pre-mortem RCA**” (Tìm nguyên nhân gốc rễ chủ động dựa trên mô hình nhân quả cấu trúc) trong bối cảnh vi dịch vụ. Đây không phải là một chứng minh toán học tổng quát cho mọi lớp đồ thị DAG liên tục, mà được giới hạn nghiêm ngặt trong lớp mô hình **Additive Noise Model (ANM)** phi tuyến hoặc tuyến tính có thể học được từ dữ liệu thực tế. Khung phương pháp luận này giả định đồ thị nhân quả đã được xác định trước bởi các kỹ sư hệ thống hoặc học từ các công cụ khám phá nhân quả tin cậy.

5.2 Luận điểm 1: Định lý Phân rã Cắt cụt (Truncated Factorization Theorem)

Định lý Phân rã cắt cụt (Truncated Factorization Theorem) của Judea Pearl được định nghĩa nguyên bản như sau:

$$P(x_1, \dots, x_n \mid do(X_i = x_i^*)) = \prod_{j \neq i} P(x_j \mid pa_j) \Big|_{X_i = x_i^*} \quad (\text{Pearl, 2009, Chapter 3, Eq. 3.10})$$

Biện giải toán học và lập luận về tính nhận dạng (Identifiability): Theo Pearl (2009), phân phối can thiệp được xác định chính xác bằng công thức phân rã cắt cụt:

$$P(x_1, \dots, x_n \mid do(X_i = x_i^*)) = \prod_{j \neq i} P(x_j \mid pa_j) \Big|_{X_i = x_i^*} \quad (18)$$

Công thức trên chứng minh rằng đối với tất cả các nút hạ nguồn X_j ($j \neq i$), phân phối có điều kiện $P(X_j \mid PA_j)$ hoàn toàn trùng khớp và bất biến dưới tác động của can thiệp.

Lưu ý quan trọng về tính Nhận dạng và sự Giới hạn của từ “Tuyệt đối”: Trong các công trình trước đây, việc đánh giá tác động can thiệp đòi hỏi phải chạy các thuật toán nhận dạng (identifiability algorithms) phức tạp bằng cách áp dụng 3 quy tắc do-calculus của Pearl (1995). Việc chứng minh tính đầy đủ (completeness) của hệ thống do-calculus này đã được thực hiện chính thức bởi Huang và Valtorta (2006) trong bài báo đoạt giải Best Student Paper tại hội nghị UAI 2006 (“Pearl’s Calculus of Intervention Is Complete”). Nghiên cứu này chỉ ra rằng nếu một hiệu ứng nhân quả là có thể nhận dạng được (identifiable), luôn tồn tại một chuỗi hữu hạn các phép biến đổi do-calculus để đưa nó về dạng chỉ chứa các đại lượng quan sát được.

Trong phương pháp Future RCA, việc giả định đã sở hữu một Mô hình Nhân quả cấu trúc (SCM) đầy đủ giúp chúng ta nói lỏng rào cản này: các truy vấn can thiệp và phản thực tế trở nên **tầm thường về mặt tính toán** (computationally trivial) vì ta có thể trực tiếp chạy lan truyền mô phỏng mà không cần chạy thuật toán do-calculus để tìm dạng tường minh. Tuy nhiên, điều này **không đồng nghĩa với việc kết quả dự phóng sẽ giữ nguyên tính đúng đắn tuyệt đối trong thế giới thực**. Độ đúng đắn của dữ liệu giả lập phụ thuộc hoàn toàn vào mức độ trùng khớp giữa hàm f_j đã fit và phân phối nhiễu $P(N_j)$ với cơ chế vật lý thật của hệ thống. Nếu SCM bị lệch cấu trúc hoặc thiếu các biến ẩn quan trọng (confounders), kết quả dự phóng sẽ bị sai lệch nghiêm trọng.

5.3 Luận điểm 2: Sự bảo toàn tính độc lập của các nguồn nhiễu

Tính chất Mô-đun (Modularity) của cơ chế nhân quả được Blöbaum et al. định nghĩa nguyên bản trong tài liệu công cụ:

“These mechanisms are assumed to be modular, i.e., we can independently change the causal mechanism of one variable without affecting the causal mechanisms of other variables in the system.” (Blöbaum et al., 2022, p. 1)

Ý nghĩa lý thuyết và lập luận khoa học: Phép can thiệp $do(X_i = x_i^*)$ chỉ thay thế cơ chế tại nút X_i thành hằng số, cắt bỏ các cạnh đi vào từ PA_i . Dựa trên thuộc tính **Mô-đun (Modularity)** (Peters et al., 2017), việc can thiệp này hoàn toàn không làm thay đổi các biến nhiễu nội tại N_j ($j \neq i$) tại hạ nguồn. Do đó, các biến nhiễu tiếp tục duy trì thuộc tính độc lập thống kê đồng thời ($N_j \perp\!\!\!\perp N_k$). Điều này đảm bảo điều kiện tiên quyết của Theorem 1 và Theorem 3 luôn được thỏa mãn trên dữ liệu giả lập.

5.4 Luận điểm 3: Tính bất biến cấu trúc hàm mục tiêu và sự hội tụ của Theorem 3

Biến đích ở hạ nguồn X_n luôn có thể biểu diễn dưới dạng một hàm xác định của các biến nhiễu tổ tiên:

$$X_n = \psi(N_1, \dots, N_n) \quad (19)$$

Dưới tác động của toán tử can thiệp $do(X_k = x_k^*)$, phương trình này chuyển dịch thành:

$$X_n = \psi'(N_1, \dots, N_{k-1}, N_{k+1}, \dots, N_n \mid x_k^*) \quad (20)$$

Vì hàm mới ψ' vẫn là một hàm xác định và nhận đầu vào là các biến nhiễu hoàn toàn độc lập thống kê $N_{j \neq k}$, nên theo đúng chứng minh của Theorem 3 (Janzing et al., 2019), tổng điểm ngoại lệ của nút đích dưới kịch bản can thiệp vẫn phân rã hoàn hảo tuyệt đối:

$$S(x_n \mid do(X_k = x_k^*)) = \sum_{j \neq k} cSh_{x^*}(j) \quad (21)$$

5.5 Luận điểm 4: Rào cản an toàn hệ thống thông qua Bổ đề 3 (Lemma 3)

Bổ đề 3 (Lemma 3) cùng lập luận của tác giả về giới hạn an toàn của sự lây lan bất thường được phát biểu nguyên văn:

“For any $\Delta \in \mathbb{R}_0^+$ we have:

$$P\{S(Y) \geq c + \Delta \mid S(X) \geq c\} \leq e^{-\Delta}$$

Plugging an outlier x with $S(x) \geq c$ into any causal mechanism $P_{Y|X}$ is unlikely to cause an effect y whose outlier score is significantly larger than c .” (Janzing et al., 2019, p. 4)

Ý nghĩa toán học và lập luận bảo chứng hệ thống: Để đảm bảo việc mô phỏng tải cực Surge không làm phép tính toán bị mất ổn định dẫn đến các cảnh báo giả, bổ đề 3 thiết lập một rào cản an toàn:

Bổ đề 3 (Janzing et al., 2019, p. 4). *Với mọi $\Delta \in \mathbb{R}_0^+$, ta luôn có giới hạn xác suất sau:*

$$P\{S(Y) \geq c + \Delta \mid S(X) \geq c\} \leq e^{-\Delta} \quad (22)$$

Bổ đề này chứng minh rằng một ngoại lệ nhẹ ở thượng nguồn (trễ nhẹ do tính năng mới gây ra) rất khó có thể tự động khuếch đại thành một sự cố nghiêm trọng (sập hệ thống) ở hạ nguồn, do xác suất bị chặn trên bởi hàm mũ giảm cực nhanh $e^{-\Delta}$.

6 Cảnh báo Học thuật và Thách thức Thực tế (Limitations & Risks)

Để đảm bảo tính khách quan khoa học, nghiên cứu này chủ động khai báo các rào cản lý thuyết, điểm mù ngoại suy và rủi ro chồng tầng suy luận khi ứng dụng phương pháp Future RCA vào thực tế.

6.1 Rủi ro chồng ba tầng suy luận (Triple-Decker Inference Risk)

Khác với các phương pháp chẩn đoán lỗi bị động thông thường, phương pháp Future RCA lồng ghép liên tục ba tầng suy luận thống kê và nhân quả, tạo ra một chuỗi tích lũy sai số (error propagation):

1. **Tầng 1 - Học cấu trúc (Structure Learning):** Xác định đồ thị DAG G từ dữ liệu quan sát. Bất kỳ sai lệch nào về hướng của cạnh nhân quả hoặc sự thiếu hụt nút do nhiễu loạn đều làm sai lệch cấu trúc của toàn bộ hệ thống hạ nguồn.
2. **Tầng 2 - Học cơ chế nhân quả (Mechanism Fitting):** Ước lượng các hàm số f_j và khớp phân phối nhiễu nội tại $P(N_j)$. Sai số từ việc xấp xỉ hàm (ví dụ: dùng hồi quy tuyến tính cho quan hệ phi tuyến) sẽ tích lũy trực tiếp vào các biến nhiễu tái dựng.
3. **Tầng 3 - Giả lập phản thực tế & Phân rã Shapley (Counterfactual Aggregation):** Chạy lan truyền xuôi dòng và tính điểm đóng góp Shapley qua hàng ngàn kịch bản Monte Carlo.

Vì sai số của tầng trước sẽ làm bùng nổ sai số ở tầng sau, chúng tôi khuyến cáo các kỹ sư hệ thống không nên kỳ vọng một độ chính xác tuyệt đối mà cần xem đây là một công cụ hỗ trợ định hướng rủi ro tương đối.

6.2 Cảnh báo ngoại suy ngoài miền phân phối (OOD Extrapolation Failure)

Như đã phân tích tại phần thiết lập hàm f , các mô hình phản thực tế học từ dữ liệu lịch sử thường trở nên kém tin cậy hoặc hoàn toàn sụp đổ khi hệ thống hoạt động ở các vùng biên cực hạn chưa từng có trong tập huấn luyện (Nagalapatti, 2025).

- Các mô hình học máy phức tạp dạng cây (như Random Forest, GBDT) có điểm mù chí mạng là **không thể ngoại suy OOD**, chúng sẽ trả về các giá trị hằng số biên khi nhận mức tải giả lập quá lớn.
- Do đó, nghiên cứu này khuyến cáo bắt buộc phải sử dụng các mô hình có cấu trúc toán học ổn định như **Linear ANM** cho các nút tài nguyên để tận dụng xu hướng ngoại suy tuyến tính, và các mô hình dựa trên **Lý thuyết hàng đợi (Queueing Theory)** như *QueueingLatencyRegressor* cho các nút độ trễ để phản ánh đúng hiện tượng bão hòa nghẽn cổ chai vật lý.

6.3 Độ nhạy đối với kích thước hệ thống (Scale Sensitivity)

Các thực nghiệm độc lập chỉ ra rằng hiệu năng của các phương pháp định vị nguyên nhân gốc rễ SCM nhạy cảm rất mạnh với kích thước của hệ thống phần mềm:

- **On system small (như Sock Shop - 11 đến 15 nút):** Thuật toán chẩn đoán và dự phóng đạt độ chính xác cực kỳ cao, do đồ thị nhân quả dễ xác lập chuẩn xác và tương tác giữa các service ít phi tuyến đan xen phức tạp.

- **On system large (như Train Ticket - 64 nút trở lên):** Rủi ro sai lệch đồ thị (graph mismatch) tăng lên đáng kể do số lượng liên kết bùng nổ. Thời gian tính toán cho việc lặp qua 2^n liên minh Shapley cũng tăng theo cấp số nhân, đòi hỏi phải áp dụng các kỹ thuật xấp xỉ Shapley (như Shapley sampling) để tối ưu thời gian chạy.

6.4 Không có phương pháp nhân quả nào chiến thắng trong mọi tình huống

Chúng tôi thẳng thắn thừa nhận và công bố kết quả thực nghiệm khách quan: Mô hình Nhân quả cấu trúc (SCM/FCM) là công cụ mạnh mẽ nhất trong việc chẩn đoán phi tuyến và giả lập phản thực tế, nhưng nó không phải là chìa khóa vạn năng giải quyết mọi sự cố. Trong các thực nghiệm so sánh đa dạng (như trên các tập benchmark RCAEval công khai), SCM giành chiến thắng thuyết phục trong khoảng **33.3% (7/21 kịch bản sự cố)**, trong khi các phương pháp thống kê truyền thống hoặc học máy phi nhân quả vẫn có ưu thế trong các lỗi dạng nhiễu trắng đơn giản hoặc hệ thống tuyến tính thuần túy.

Do đó, việc báo cáo cả độ chính xác (Accuracy) lẫn thời gian huấn luyện và thời gian suy diễn (Inference/Train Time) dưới dạng một **Ma trận Đánh đổi (Trade-off Matrix)** là cực kỳ cần thiết để người vận hành đưa ra quyết định lựa chọn công cụ phù hợp với hạ tầng thực tế.